

Maschinelles Lernen

Grundlagen und betriebswirtschaftliche Anwendungspotenziale am Beispiel von Kundenbindungsprozessen

Andreas Welsch · Verena Eitle · Peter Buxmann

Eingegangen: 29. November 2017 / Angenommen: 21. Februar 2018 / Online publiziert: 5. März 2018
© Springer Fachmedien Wiesbaden GmbH, ein Teil von Springer Nature 2018

Zusammenfassung Die zunehmende Digitalisierung sowie die allgegenwärtige Verfügbarkeit von Daten verändern das Wirtschaftsleben, den Alltag des Einzelnen und die Gesellschaft als Ganzes. Vor diesem Hintergrund wird der Einsatz von maschinellen Lernverfahren in vielen Bereichen von Wirtschaft und Gesellschaft zum Teil kontrovers diskutiert. Mit Hilfe des Einsatzes solcher Algorithmen lassen sich beispielsweise Prognosen verbessern sowie Entscheidungen bzw. Entscheidungsprozesse automatisieren. In diesem Artikel geben wir zum einen einen Überblick über die Grundprinzipien maschinellen Lernens. Zum anderen diskutieren wir Anwendungsmöglichkeiten sowie Wirtschaftlichkeitspotenziale am Beispiel von Kundenbindungsprozessen.

Schlüsselwörter Automatisierung von Unternehmenssystemen · Kundenbindungsmanagement · Maschinelles Lernen

Machine Learning

Introduction and Use Cases in Customer Retention Management

Abstract The increasing digitalization, as well as the ubiquitous availability of data, are currently transforming the economy, the lives of consumers, and society in general. In this context, the use of machine learning is often controversially debated by businesses and the public. For example, these algorithms can help improve

A. Welsch (✉) · V. Eitle · P. Buxmann
Technische Universität Darmstadt, Hochschulstraße 1, 64289 Darmstadt, Deutschland
E-Mail: Welsch@is.tu-darmstadt.de

V. Eitle
E-Mail: Eitle@is.tu-darmstadt.de

P. Buxmann
E-Mail: Buxmann@is.tu-darmstadt.de

making predictions and help automate decisions and decision making processes. In this paper, we first provide an overview of the basic concepts of machine learning and secondly, we will examine selected use cases and efficiency potentials within the customer retention processes.

Keywords Automation of business systems · Customer service · Customer retention management · Machine learning

1 Einleitung

Die Digitalisierung der Wirtschaft bedroht vielfach traditionelle Unternehmen, welche vermehrt mit disruptiven Ideen aufstrebender Neuankömmlinge im Wettbewerb stehen und sich oftmals aufgrund ihrer Größe und Komplexität nur langsam anpassen oder Innovation betreiben können (Christensen 1997). Allerdings bieten sich gleichzeitig auch Chancen, die bestehenden Geschäftsmodelle und -prozesse dahingehend zu transformieren bzw. neue zu entwickeln, dass weiterhin ein Wettbewerbsvorteil generiert werden kann (Chesbrough 2007; Osterwalder und Pigneur 2010). Insbesondere die fortschreitende Prozessautomatisierung wird dabei als wesentlicher Faktor der digitalen Transformation aufgeführt (World Economic Forum 2016; McKinsey 2017). Das primäre Ziel steigender Automatisierung ist es, Effizienz-, Effektivitäts- und Qualitätsverbesserungen zu realisieren (Damm und Kalmar 2017). Informationssysteme, wie Enterprise Resource Planning (ERP) und Customer Relationship Management (CRM), sind bereits seit Jahrzehnten in Unternehmen etabliert und unterstützen den Kundenbeziehungszyklus. Nicht zuletzt aufgrund der zunehmenden Vernetzung von Menschen (soziale Medien), Maschinen (Industrie 4.0) und Systemen (z.B. Cloudcomputing) steigt das globale Datenvolumen exponentiell (Huber 2016). Technologien, wie Big Data, ermöglichen es, dieses große Datenvolumen zu verarbeiten, zu analysieren und zu speichern (Schroeck et al. 2012). In Kombination mit besseren Algorithmen im Bereich künstlicher Intelligenz sowie verteilter, paralleler Datenverarbeitung wird darüber hinaus die Grundlage für Maschinelles Lernen geschaffen (Kelly 2014).

In Folge dessen entsteht eine neue Klasse „intelligenter Systeme“, die durch Fähigkeiten, wie beispielsweise Kognition (Kelly und Hamm 2013), weitere Teile bislang manuell ausgeführter Tätigkeiten übernehmen und dabei Probleme selbstständig und effizient lösen können (Mainzer 2016), ohne dass die explizite Programmierung derselben erforderlich ist. Diese intelligenten Systeme ermöglichen es, Signale und Muster in strukturierten, semi-strukturierten als auch unstrukturierten Daten zu erkennen sowie diese zu analysieren (Hurwitz et al. 2015; Reeves und Ueda 2016). Das Hauptmerkmal dieser Systeme ist dabei die sogenannte „schwache künstliche Intelligenz“, welche die Lösung eng definierter, hochspezialisierter Probleme (wie beispielsweise das autonome Fahren oder das Stellen medizinischer Diagnosen) bezeichnet¹ (Pennachin und Goertzel 2007) und hierdurch den Anschein erweckt tatsächlich intelligent zu sein oder intelligent zu agieren (Russell und Norvig

¹ Vgl. starke künstliche Intelligenz bzw. „Artificial General Intelligence“ (Pennachin und Goertzel 2007).

2010). Dennoch sind intelligente Systeme nicht nur bereits vielfach den bisherigen von Menschen programmierten Systemen überlegen, sondern auch den menschlichen Fähigkeiten selbst – teilweise bereits bei Aufgaben, die aufgrund von Kreativität und Komplexität bislang nicht automatisierbar waren (Brynjolfsson und McAfee 2017). Ein interessantes Anwendungsbeispiel ist die Optimierung von Kundenbeziehungen (Watson 2017). Aufgrund der Verfügbarkeit von großen Datenmengen sowie der steigenden Bedeutung der Kundenfokussierung sind die Bereiche der Kundenidentifizierung, -anziehung, -bindung und -entwicklung für die Anwendung von intelligenten Systemen grundlegend geeignet (Ngai et al. 2009). Da insbesondere die Loyalität der Kunden eine positive Auswirkung auf die Unternehmensprofitabilität hat (Buckinx und Van den Poel 2005), bergen intelligente Systeme ein erhebliches Potenzial im Kundenbindungsprozess. Vor diesem Hintergrund wird der Fokus in diesem Beitrag auf den Einsatz von Maschinellen Lernverfahren im Kundenbindungsmanagement gelegt mit dem Ziel die verschiedenen Anwendungsfelder sowie die damit verbundenen Optimierungsmöglichkeiten aufzuzeigen.

In diesem Kontext rückt die Änderung der Arbeitsteilung zwischen Mensch und Maschine (Softwaresystem) stärker in den Fokus der Diskussion (Bitkom 2017). Dabei wird der Übergang von entscheidungsunterstützenden hin zu entscheidungsautomatisierenden Aufgaben in Anlehnung an SAE International (2016) beschrieben (siehe Abb. 1): Innerhalb eines manuellen Systems nimmt der Mensch (Benutzer) dauerhaft alle anfallenden Aufgaben und Entscheidungen zur Zielerreichung selbst wahr, ohne dass ein Softwaresystem vorhanden oder involviert ist (Stufe 0). Auf der ersten Automatisierungsstufe unterstützt das System hingegen den Menschen bereits bei der Ausführung definierter Aufgaben, während der Mensch die Kontrolle darüber behält und Entscheidungen zur Zielerreichung selbst trifft (z.B. ERP-Systeme der 1960er- bis 1990er-Jahre). Systeme auf der zweiten Stufe übernehmen die Ausführung definierter Aufgaben, während die Kontrolle darüber beim Menschen verbleibt und dieser die Entscheidungen zur Zielerreichung selbst übernimmt (z.B. Internet- und Microservicesarchitektur der 2000er- bis 2010er-Jahre) (SAE International 2016; Bitkom 2017). Der Mensch übernimmt unter dem Schlagwort „Human-in-the-Loop“ neben der Anwendung auch die Kontrolle über das System und trifft alle relevanten Entscheidungen (Damm und Kalmar 2017).

Allerdings wird sich die Aufgabe des Menschen mittelfristig stärker hin zur Überwachung intelligenter Systeme (Stufe 3) entwickeln, bei der der Mensch im Fehlerfall einschreiten kann bzw. muss (Committee on Technology National Science and Technology Council 2016). Jedoch nimmt diese Anforderung mit steigender Automatisierung (hin zu Stufe 4) stetig ab. Davenport und Kirby (2016) beschreiben vier Ebenen der Intelligenz solcher Systeme: Unterstützung für Menschen, Automatisierung repetitiver Aufgaben, Kontextbewusstsein und Lernen, sowie Selbstbewusstsein, wobei das Erreichen der Letzteren durch starke künstliche Intelligenz realisiert wird (Pennachin und Goertzel 2007). Letztlich werden diese Systeme der fünften Stufe autonom, ohne jegliche Eingabe und Kontrolle des Benutzers, agieren, ihre Umgebung analysieren und basierend auf den gewonnenen Erkenntnissen selbstständig entscheiden (Fachforum Autonome Systeme 2017). Zudem sind sie in der Lage, auch selbstheilende Funktionen auszuführen, um das vorgegebene Ziel zu erreichen sowie die zur Ausführung einer Aufgabe erforderlichen Fähigkeiten

mittels Maschinellen Lernen selbständig zu erwerben und zu optimieren (Wahlster 2017).

Insbesondere der Übergang von menschlicher hin zu systemgetriebener Entscheidung wird dabei als ein bedeutsamer, evolutionärer Schritt wahrgenommen, der gegenwärtig durch die Einbettung Maschinellen Lernens in Unternehmenssysteme zu beobachten ist (z. B. IBM 2017; Salesforce 2017; SAP 2017b). Allerdings ergeben sich hieraus zugleich auch Risiken geringer Akzeptanz solcher Systeme, da durch die zugrundeliegende Technologie des Maschinellen Lernens Entscheidungen für den Menschen nicht mehr zwingend nachvollziehbar oder transparent sind (Davenport und Kirby 2016; Brynjolfsson und McAfee 2017). Damm und Kalmar (2017) verweisen in diesem Zusammenhang auf einen Bericht des Europäischen Parlaments (2017), in dem u. a. explizit diese Transparenz sowie Nachvollziehbarkeit der durch künstliche Intelligenz getroffenen Entscheidungen für den Menschen gefordert werden. Basierend auf der Automation des Entscheidens (siehe Abb. 1) folgt daher zunächst eine Übersicht der zugrundeliegenden Konzepte des Maschinellen Lernens sowie die anschließende Betrachtung dieser im Kontext des Kundenbindungsprozesses. Anhand von Anwendungsbeispielen aus Wissenschaft und Praxis werden die Zusammenhänge erläutert und das Potenzial Maschinellem Lernmethoden praxisnah dargestellt.

2 Grundlagen des Maschinellen Lernens

Maschinelles Lernen ist ein Teilgebiet der künstlichen Intelligenz und ist als etabliertes Forschungsgebiet seit Jahrzehnten durch einen rasanten technologischen Fortschritt geprägt. Der Begriff der künstlichen Intelligenz, welcher während der Dartmouth Conference im Jahr 1956 erstmals von Minsky, McCarthy, Newell und Simon definiert wurde, beschreibt Maschinen, die sich verhalten, als würden sie über eine Art menschliche Intelligenz verfügen (McCarthy et al. 1955). In den Folgejahren hat sich daraus das Teilgebiet Maschinelles Lernen etabliert, wobei die eigentliche Entwicklung von komplexen Algorithmen des Maschinellen Lernens erst in den 90er-Jahren voranschritt (Russell und Norvig 2010; Nilsson 2014). Einer der Schlüsselerfolge von Maschinellen Lernverfahren wurde im Jahre 2016 erzielt, als AlphaGo, ein von Google entwickeltes Computerprogramm, erstmalig einen professionellen Go-Spieler besiegte (Silver et al. 2016). Dieser Sieg wurde jedoch von Experten im Bereich der künstlichen Intelligenz laut einer Oxford-Studie erst für das Jahr 2027 prognostiziert und übertrifft somit jegliche Erwartungen (Grace et al. 2017). Die rasante technologische Weiterentwicklung zeigt sich ebenfalls durch die erst im Oktober 2017 veröffentlichte neue Version AlphaGo Zero. Dabei wird das Computerprogramm lediglich mit den Grundregeln des Go-Spiels ausgestattet und erlernt und entwickelt selbstständig iterativ neue Spielzüge. Hierdurch konnte AlphaGo Zero die letzte Version nach nur drei Tagen erfolgreich besiegen und erweitert somit die bekannten menschlichen Spielzüge (Silver et al. 2017).

Im Allgemeinen umfasst der Begriff Maschinelles Lernen Methoden, die mithilfe von Lernprozessen Zusammenhänge in bestehenden Datensätzen erkennen, um darauf basierend Vorhersagen zu treffen (Murphy 2012). Das Grundkonzept von

Maschinellen Lernverfahren definiert Mitchell als „A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P , if its performance at tasks in T , as measured by P , improves with experience E “ (Mitchell 1997, S. 2). Im Wesentlichen bedeutet dies, dass ein Modell aufgrund der selbstlernenden Algorithmen und der existierenden Daten zukunftsrelevante Rückschlüsse ziehen kann, ohne diese explizit zu programmieren. Als Grundlage für diese Lernprozesse dienen Instanzen als Dateneingabe, die sich durch eine vordefinierte Reihe an Attributen charakterisieren. Dabei kann es sich um kontinuierliche, kategorische oder binäre Werte der Attribute handeln (Murphy 2012; Witten et al. 2017).

Maschinelle Lernverfahren werden u. a. in folgende Kategorien gegliedert: überwachtes (eng. supervised learning), unbewachtes (eng. unsupervised learning) und bestärktes Lernen (eng. reinforcement learning) (Russell und Norvig 2010). Sofern ein dedizierter Ausgabewert definiert ist, kann durch überwachte Maschinelle Lernverfahren das Modell dahingehend trainiert werden, dass der Ausgabewert bei einem bisherigen unbekannten Datensatz – dem Test Set – vorhergesagt wird. Im Allgemeinen besteht das eigentliche Ziel des überwachten Lernens darin, die Genauigkeit dieser Vorhersagen zu maximieren. Die zweite Kategorie des Maschinellen Lernens wird vor allem dann angewandt, wenn ein Datensatz keine präzisen Ausgabewerte aufweist. Daher können durch die Anwendung von unbewachten Maschinellen Lernalgorithmen basierend auf den Eingabedaten bisher unbekannte Muster und Zusammenhänge abgeleitet werden. Bei der zuletzt genannten Kategorie, dem bestärkten Lernen, basiert der Lernprozess des Algorithmus auf den Formen der Belohnung und Bestrafung mit dem Ziel, den Nutzen zu maximieren (Russell und Norvig 2010; Murphy 2012; Marsland 2015). Aufgrund des hohen Akzeptanzgrades der ersten Kategorie werden im Folgenden die verschiedenen Methoden und Anwendungsfälle des überwachten maschinellen Lernens aufgezeigt und erläutert (Brynjolfsson und McAfee 2017).

Ziel des überwachten Lernverfahrens ist es, den Ausgabewert anhand der vorhandenen Eingabewerte – den Attributen – mit einer möglichst hohen Genauigkeit vorherzusagen. Um dieses Ergebnis an bisher unbekannten Daten validieren zu können, wird der gesamte Datensatz in ein Training Set und ein Test Set aufgeteilt. Der eigentliche Lernprozess zur Vorhersage der Zielvariable basiert auf dem Training Set, wohingegen die Evaluierung dieses trainierten Modells mithilfe des Testdatensatzes erfolgt. Dadurch kann sichergestellt werden, dass die Bewertungsgrößen, wie Genauigkeit und Fehlerquote, anhand bisher unbekannter Daten bestimmt werden (Russell und Norvig 2010; Murphy 2012; Marsland 2015). Zudem ist anzumerken, dass innerhalb des Training Sets die Hyperparameter des Lernalgorithmus anzupassen sind, um die Leistung des Modells zu steigern. Eine gängige Methode zur Messung dieser Anpassungen ist die k -fache Kreuzvalidierung, die das Training Set in k Untermengen teilt. Da das Modell auf den $k-1$ Untermengen trainiert und mit der verbleibenden Teilmenge validiert wird, kann der Durchschnitt der Bewertungsgrößen über die k -fachen Durchläufe gebildet werden und stellt somit einen verlässlichen Leistungsindikator dar (Kohavi 1995). Bevor der eigentliche Lernalgorithmus selektiert und eingesetzt wird, ist aus Gründen der Datenqualität der Prozess der Datenvorverarbeitung anzuwenden. Die dabei verwendeten Methoden

Tab. 1 Anwendungsfälle für überwachte Lernverfahren

Input	Output	Applikation	Lernalgorithmen
Kreditantrag Informationen	Annahme/Ablehnung	Kreditvergabe	Random Forest Nearest Neighbor Neuronale Netze Support Vector Machine
Störungen	Vorhersage des Fehlertyps	Maschinenkomponente	Nearest Neighbor Support Vector Machine
Bilder von Personen	Identifikation der Personen	Gesichtserkennung	Neuronale Netze
Text	Klassifizierung	Spam Mails/ Bewertungen	Random Forest Nearest Neighbor
Medizinische Bilder	Krankheitsdiagnose	Medizin	Neuronale Netze
Tonaufzeichnungen	Text	Sprachassistent	Neuronale Netze

dienen vor allem der Bereinigung von fehlerhaften Daten, bestehenden Ausreißern und fehlenden Werten (Batista und Monard 2003). Zudem kann die Genauigkeit der Ergebnisvorhersage durch Verfahren der Feature Selection erhöht werden, da irrelevante und überflüssige Attribute entfernt werden, welche anderenfalls das Ergebnis irreführend beeinflussen würden (Yu und Liu 2004).

Die Auswahl des Lernalgorithmus hängt speziell von dem zu lösenden Problem des überwachten Maschinellen Lernens ab. Sofern die Zielvariable einen diskreten Wert darstellt, handelt es sich um ein Klassifikationsproblem, da bisher unbekannte Instanzen aufgrund der vorhandenen Attribute den Klassen der Ausgabewerte zuzuordnen sind. Dahingegen charakterisiert sich das Regressionsproblem durch die Vorhersage einer kontinuierlichen Zielvariable, die eine reelle Zahl darstellt (Murphy 2012; Marsland 2015). Anhand dieser zwei Verfahren des überwachten Maschinellen Lernens – Klassifikation und Regression – lassen sich für Unternehmen und Institutionen eine Vielzahl an Lernaufgaben bewältigen. Um das hohe Potenzial an überwachten Lernverfahren im Unternehmensumfeld und in verschiedenen Industrien aufzuzeigen, werden im Folgenden verschiedene Anwendungen genannt, die sich hierfür insbesondere eignen (siehe Tab. 1). Im Bereich der Finanzdienstleistung können beispielsweise durch die Anwendung von überwachten Lernverfahren die Entscheidungsprozesse der Kreditvergabe optimiert sowie Aktienkurse analysiert werden (z.B. Kruppa et al. 2013; Patel et al. 2015). In der Fertigungsindustrie beziehen sich die Anwendungsfälle des Maschinellen Lernens vornehmlich auf Fehlertypenerkennung und prädiktive Wartung von Anlagen und Maschinenkomponenten, um die hochkomplexen Prozesse der Experten zu automatisieren (z.B. Yin et al. 2014; Susto et al. 2015). Im Bereich der Bildklassifikation wurde durch den Einsatz von Maschinellen Lernverfahren ein erheblicher Fortschritt erzielt. Neben der Erkennung von allgemeinen Objekten, wie Tieren oder Pflanzen in Bildern, profitieren vor allem Bereiche, wie soziale Medien sowie Überwachungs- und Sicherheitssysteme, durch die eindeutige Identifikation von Personen und Bestimmung von Emotionen (z.B. Murphy 2012). Ein weiteres weitverbreitetes Anwendungsgebiet ist die Klassifizierung von Dokumenten in Form von Artikeln, Textabschnitten oder

Websites, die beispielsweise der Zuordnung von Web Spam, Rechnungen, Verträgen und Kundenbewertungen dienen (z.B. Guzella und Caminhas 2009; Murphy 2012). Sofern die Bild- und Textanalyse in Betracht gezogen wird, hat sich das Maschinelle Lernen ebenfalls stark in der Medizin etabliert, da u.a. anhand von medizinischen Bildern und Texten Krankheitsdiagnosen, wie Krebserkrankungen prognostiziert werden können (z.B. Litjens et al. 2017). Neben der Bild- und Textverarbeitung zählt außerdem die Spracherkennung zu einem Fokusbereich, bei dem Tonaufzeichnungen in Text übersetzt werden. Dieses Gebiet hat sich insbesondere durch die Entwicklung der personellen virtuellen Sprachassistenten, wie Siri (Apple 2017), Alexa (Amazon Developer 2017) und Google Now (Google 2017), im Markt etabliert.

Nachdem die Datenqualität durch den Prozess der Datenvorverarbeitung gegeben und das Klassifikations- oder Regressionsproblem identifiziert ist, erfolgt die eigentliche Selektion des überwachten Lernalgorithmus. Die geläufigsten überwachten Lernalgorithmen werden im Folgenden kurz dargestellt. Der Grundgedanke des *Nearest Neighbor* Algorithmus ist, dass ein Datenpunkt basierend auf dem Mehrheitsentscheid benachbarter Datenpunkte einer bestimmten Klasse zugeordnet wird (Russell und Norvig 2010). Bei der Verwendung von *Entscheidungsbäumen* werden Instanzen anhand ihres Pfades, ausgehend von dem Wurzelknoten und den einzelnen inneren Knoten, durch Entscheidungsregeln einer Klasse zugeteilt (Quinlan 1986; Murthy 1998). Als eine Erweiterung dieses Verfahrens gilt der *Random Forest* Algorithmus, welcher die Klassenzuordnung durch den Mehrheitsbeschluss von unabhängigen Entscheidungsbäumen vornimmt (Breiman 2001). Der Support Vector Machine Algorithmus verwendet eine Hyperebene, welche die Klassen mit dem möglichst größten Abstand voneinander trennt (Cortes und Vapnik 1995; Russell und Norvig 2010). Aufgrund der wachsenden Komplexität und Menge der Datensätze haben sich vor allem künstliche neuronale Netze etabliert, welche sich auf abstrakter Ebene an der biologischen Informationsverarbeitung orientieren. Das neuronale Netz besteht aus einer Anzahl an Neuronen, die durch ihre Anordnung und Verbindung Informationen modifiziert weiterleiten. Die Intensität der Verbindung der Neuronen basiert auf Gewichtungen, welche innerhalb des Lernprozesses durch Lernregeln des überwachten Lernens anhand des bekannten Ausgabewerts verändert werden (Marsland 2015; Mainzer 2016). Um die Gesamtleistung zu steigern, können zudem Boosting-Verfahren, wie der AdaBoost Algorithmus, eingesetzt werden, welche eine Vielzahl von schwachen Klassifikatoren durch einen gewichteten Mehrheitsentscheid zu einem einzigen Klassifikator kombinieren (Schapire und Freund 2012). Zusätzlich zu den zuvor beschriebenen Beispielen finden Maschinelle Lernverfahren zunehmend Anwendung im Bereich des Kundenbindungsmanagements – insbesondere mit dem Ziel, die Kundenzufriedenheit zu erhöhen sowie das Risiko abwandernder Kunden zu reduzieren (Bruhn und Hadwich 2012). Diese Kundenfokussierung lässt sich vor allem durch die positiven Wirkungszusammenhänge zwischen dem Erhalt der existierenden Kundenbasis sowie der steigenden Unternehmensprofitabilität begründen (Buckinx und Van den Poel 2005; Jahromi et al. 2014). Daher wird nachfolgend die Anwendung von Maschinellen Lernverfahren im Bereich des Kundenbindungsmanagements anhand von Beispielen aus Wissenschaft und Praxis beleuchtet.

3 Maschinelles Lernen als Werkzeug des Kundenbindungsmanagements

Neben der Kundenbindung und der Kundenrückgewinnung gilt die Kundenakquise typischerweise als die kostenintensivste Phase des Kundenbeziehungszyklus (z. B. Reinartz und Kumar 2003; Reinartz et al. 2004). Unternehmen investieren daher in Kundenbindungsmaßnahmen und -systeme, um Bestandskunden an die eigenen Produkte und Dienstleistungen zu binden. Hierzu werden diverse Datenquellen und -punkte herangezogen, wie beispielsweise Transaktionshistorie, Produktfehlerhäufigkeit, Produktkategorien, sozioökonomischer Status und Mitgliedschaften in Kundenbindungsprogrammen (Tamaddoni et al. 2016) sowie Informationen über soziale Netzwerke (Verbeke et al. 2014). Je nach Anwendungsfall² gilt es die am besten geeigneten Attribute zu identifizieren und zu gewichten (Wang et al. 2009). Aufgrund des hohen Datenvolumens wird es für Menschen allerdings immer schwieriger diese Daten selbst zu analysieren, wodurch der Einsatz Maschinellem Lernverfahren sowie zunehmender Automatisierung erforderlich wird (Vgl. Abschn. 1). Dies ist besonders in den Prozessen des Beschwerde- und Abwanderungspräventionsmanagements zu beobachten, weshalb im Folgenden die Optimierungspotentiale Maschinellem Lernverfahren dargestellt werden.

3.1 Maschinelles Lernen: Modelle zur Prognose von Kundenabgängen

Ein Hauptbestandteil des Kundenbindungsprozesses ist die Identifikation von Bestandskunden, die aufgrund geringer Kundenzufriedenheit, starkem Wettbewerb oder vorhandener Unsicherheit mit hoher Wahrscheinlichkeit die Kundenbeziehung beenden möchten (Zorn et al. 2010). Burez und Van den Poel (2007) unterscheiden zwischen der reaktiven und proaktiven Kundenabwanderung, wobei durch den letzteren Ansatz potentielle Kündigungen anhand des Kundenverhaltensmusters frühzeitig identifiziert und darauf basierend dedizierte Kundenbindungsprogramme entwickelt werden können. Aufgrund der großen Ansammlung an Kundendaten in ERP- und CRM-Systemen sowie externer Datenquellen kann die Rate der potentiellen Kundenabgänge durch die Anwendung von Maschinellen Lernverfahren rechtzeitig prognostiziert werden.

Insbesondere in der Telekommunikationsindustrie haben sich aufgrund der hohen Anzahl an Kündigungen Prognosemodelle, basierend auf Maschinellem Lernverfahren, zur Bestimmung von Kundenabgängen etabliert (z. B. Hung et al. 2006; Kirui et al. 2013). Vafeiadis et al. (2015) untersuchen in ihrer Studie die potentielle Kundenabsprungrate von Telekommunikationskunden anhand der Verhaltensmuster der Telefonate, wie beispielsweise Anzahl, Dauer und Tageszeit. Bei der Vorhersage dieser potentiellen Kundenabgänge erzielt der Support Vector Machine Algorithmus durch die Anwendung von Boosting-Verfahren neben dem Entscheidungsbaum und dem neuronalen Netz die höchste Genauigkeit von 96,85 %. Des Weiteren finden Maschinelle Lernverfahren im Bereich von Abonnementsdiensten Anwendung, um exakte Prognosen der potentiellen Kundenabgänge zu ermitteln, die den Abon-

² Vgl. Telekommunikation (Wang et al. 2009; Verbeke et al. 2014) und Finanzwesen (Farquad et al. 2014).

nementvertrag nicht verlängern möchten. Dies ist vor allem für Unternehmen mit Abonnement-basierten Geschäftsmodellen von hoher Bedeutung, da laut einer Studie des Marktforschungsunternehmens Forrester³ 67 % der gesamten Abonnement-Kündigungen der 204 befragten Fachkräfte auf bewusste Entscheidungen durch Kundenunzufriedenheit zurückzuführen sind (Vallis 2017). Die Untersuchung von Coussement und Van den Poel (2008) zeigt auf, dass Attribute, wie beispielsweise Vertragsdauer, Vertragsende, Anzahl an Reklamationen und Vertragsaussetzungen, wichtige Indikatoren für potentielle Kündigungen darstellen. Das beste Ergebnis des Prognosemodells wird mit dem Random Forest Algorithmus erzielt, wobei durch die Anpassung der Hyperparameter, wie in Abschn. 2 beschrieben, des Support Vector Machine Algorithmus die Leistung des Logistic Regression Algorithmus übersteigt. Neben den vorhandenen Kundendaten aus den ERP- und CRM-Systemen kann die Vorhersage an Abonnementskündigungen durch Gefühlsäußerungen in Medien, wie Emails und Blogposts, noch präziser bestimmt werden. Durch die Einbeziehung von positiven und negativen schriftlichen Äußerungen in Beschwerde- und Informations-Emails kann die Prognoserate von potentiellen Kundenabgängen gesteigert werden. Dabei ist anzumerken, dass der Random Forest Algorithmus zum wiederholten Male die Leistung des Support Vector Machine und Logistic Regression Algorithmus übertrifft (Coussement und Van den Poel 2009). Bevor es jedoch zu möglichen Kundenabgängen kommt, wird dem Kundenservice und Beschwerdemanagement eine zentrale Aufgabe zugeteilt, welche nachfolgend erläutert wird.

3.2 Transformation des Kundenservice und Beschwerdemanagements in der Praxis – eine simulative Wirtschaftlichkeitsanalyse

Im Rahmen des Kundenservice und des Beschwerdemanagements kontaktieren Kunden den Anbieter über verschiedene Kanäle, wie beispielsweise Email, soziale Medien, mobile Applikationen oder Telefon, um Informationen zu Produkten und Dienstleistungen anzufordern oder Probleme bei der Bedienung derselben zu melden (Niefind und Wiegand 2010). Nicht zuletzt haben sich die Erwartungen der Kunden aufgrund der fortschreitenden Digitalisierung an die Verfügbarkeit von Informationen verändert, wodurch die prompte Beantwortung und Bearbeitung von Fragen über diverse Kanäle vielfach zur Selbstverständlichkeit geworden ist (Dahlmeier 2017). Daher ist es für Mitarbeiter in diesen kundennahen Funktionen wichtig, die einkommenden Anfragen anhand ihrer Dringlichkeit richtig zu priorisieren sowie eine zeitnahe und korrekte Antwort zu finden und an den Kunden zu kommunizieren. Je nach Unternehmensgröße beläuft sich das monatliche Volumen mitunter auf mehrere zehntausend eingehende Anfragen (SAP 2017a). Dabei können die Belange der Kunden häufig in definierte inhaltliche Kategorien sowie zusätzlich in *Fragen*, *Lob* und *Beschwerden* eingeteilt werden. Diese Kategorisierung wird zuweilen dennoch häufig von Menschen ausgeführt. Vor allem vor dem Hintergrund der Effizienzsteigerung sowie der Kostensenkung ermöglichen es Maschinelle Lernverfahren in Systemen des Kundenbeziehungsmanagements diese Kategorisierung nun automatisiert durchzuführen (SAP 2017a). Zudem werden historische Informationen bezüglich

³ Durchführung der Studie im Jahr 2017.

der Beantwortung eingegangener Anfragen als Basis für Lösungsvorschläge durch das System herangezogen und den Servicemitarbeitern vorgeschlagen, wodurch zusätzliche Effizienzgewinne realisiert werden können. Als wesentliche Kennzahlen zur Steuerung von Kundenkontaktzentren nennen Egle et al. (2014) u. a. die *Erledigung [einer Anfrage; Anm. d. Verf.] beim ersten Kontakt* sowie die *durchschnittliche Bearbeitungsdauer*. Durch den Einsatz Maschineller Lernverfahren können diese Kennzahlen beispielsweise signifikant verbessert werden. Aus Unternehmenssicht können sich die Mitarbeiter somit nun idealerweise auf höherwertige Aufgaben, wie die direkte Interaktion mit dem Kunden, fokussieren (Dahlmeier 2017). Aus technischer Sicht handelt es sich bei der Kategorisierung sowie den Lösungsvorschlägen um ein Klassifizierungsproblem (Vgl. Abschn. 2). Ein Beispiel: Der Softwareanbieter SAP integriert verstärkt Maschinelle Lernverfahren in Geschäftsanwendungen, wie beispielsweise im Bereich des Kundenservice und des Beschwerdemanagements mit dem Produkt *SAP Service Ticket Intelligence* (SAP 2017b). Dieses basiert auf einem künstlichen neuronalen Netz, welches bereits auf großen Mengen an Daten vortrainiert wurde und somit die Klassifizierung eingehender Anfragen sowie die Unterbreitung von Lösungsvorschlägen mit geringem Aufwand vornehmen kann (SAP 2017d). Diese Komponenten werden als Application Programming Interfaces (API) bereitgestellt (SAP 2017d).

Die nachfolgend dargestellte simulationsbasierte Wirtschaftlichkeitsanalyse zeigt beispielhaft die Potenziale des Einsatzes von Maschinellen Lernverfahren für das oben beschriebene Szenario. Die in der Simulation angenommenen Parameterwerte basieren zum Teil auf Praxiserfahrungen sowie auf Informationen aus der Literatur (Vgl. Erichsen 2007; SAP 2017c). Es wird für das Kundenkontaktzentrum eines global agierenden Unternehmens nachfolgend monatlich *100.000 eingehende Anfragen* sowie eine *manuelle durchschnittliche Bearbeitungsdauer von 5,325 min*⁴ pro Anfrage und eine *durchschnittliche Dauer von 2 s*⁵ für die *automatisierte Bearbeitung* durch das IT-gestützte System angenommen (siehe Tab. 2). Weitere Annahmen betreffen die *Automatisierungsrate* (hier: 50 %) sowie die *Genauigkeit des Modells* (hier: 80 %). Dabei bezeichnet die Automatisierungsrate die kombinierte Quote der Anfragen für die das System sowohl einen Vorschlag für die Kategorie als auch für die Lösung unterbreiten kann, und die Genauigkeit des Modells das Verhältnis aus korrekten Vorschlägen zu den gesamten Vorschlägen. Diese Werte variieren in der Praxis in Abhängigkeit der individuellen Daten, Kategorien und historischen Lösungen. Ausgehend von einer vollständig manuellen Kategorisierung und Lösung (Option 0) bietet das vortrainierte Modell (Option 1) für diverse Anwendungsbereiche bereits vielfach akzeptable Resultate. Ist eine höhere Genauigkeit der automatisierten Klassifizierung erwünscht (Option 2), geht dies meist zulasten der Automatisierung, da das Spektrum der in Frage kommenden Datenpunkte verkleinert wird und die Zahl der manuell zu bearbeitenden Anfragen steigt. Umgekehrt führt eine höhere Automatisierungsrate hingegen (Option 3) zu einer niedrigeren Genauigkeit des

⁴ Vgl. hierzu „Durchschnittliche Beratungszeit“, typische Bandbreite von 1,95–8,7 min bei Erichsen (2007).

⁵ Konservative Annahme für zwei API-Calls (Kategorisierung und Lösungsvorschlag) bedingt durch eventuelle Latenz und Verarbeitungsdauer; basierend auf Test via SAP API Business Hub (SAP 2017c).

Tab. 2 Simulation: Verkürzung der Bearbeitungsdauer durch Maschinelle Lernverfahren

	(0) Keine Automatisierung	(1) Vortrainiertes Modell	(2) Höhere Genauigkeit	(3) Höhere Automatisierung	(4) Höheres Volumen
Eingehende Anfragen (Anzahl pro Monat)	100.000	100.000	100.000	100.000	125.000
Automatisierungsrate (Anzahl automatisierbarer Anfragen)	0 (0 %)	50.000 (50 %)	40.000 (40 %)	65.000 (65 %)	62.500 (50 %)
Genauigkeit des Modells (Anzahl korrekt klassifizierter Anfragen)	–	40.000 (80 %)	36.800 (92 %)	45.500 (70 %)	50.000 (80 %)
Erledigung beim ersten Kontakt (Anteil korrekt klassifizierter Anfragen des Gesamtvolumens)	–	40 %	37 %	46 %	40 %
Gesamtvolumen Arbeitszeit (in Minuten)					
<i>Manuell</i>					
5.32500	532.500,00	213.000,00	195.600,00	242.287,50	266.250,00
<i>Automatisiert</i>					
0.03333	0	1333,33	1226,67	1516,67	1666,67
Gesamtvolumen Arbeitszeit (in Personentagen)					
<i>Manuell</i>					
0.01109	1109,38	443,75	408,25	504,77	554,69
<i>Automatisiert</i>					
0.00007	0	2,78	2,56	3,16	3,47

Modells, da sich das Spektrum der in Frage kommenden Datenpunkte erweitert. In Folge dessen steigt der Aufwand zur manuellen Nacharbeit und Korrektur. Bei einem saisonalen, zusätzlichen Anfragevolumen von 25 % und unter sonst gleichbleibenden Parametern sowie der Nutzung des vortrainierten Modells (Option 4) sind bei manueller Ausführung proportional höhere Ressourcenaufwände erforderlich. Hier ermöglichen Maschinelle Lernverfahren eine entsprechend flexiblere und dynamischere Skalierung. Im untenstehenden Beispiel wird eine deutliche Effizienzsteigerung erzielt und die vorhandenen Ressourcen stehen nun rund 2,2–2,8 Personenjahre (ca. 408–555 Personentage) mehr für eigentliche Kundenbindungsaufgaben zur Verfügung. Insgesamt ist zu beobachten, dass eine höhere Automatisierungsrate – trotz niedriger Genauigkeit – zwar zu einem höheren Wert der *Erledigung beim ersten Kontakt* führt, dies jedoch kritisch in Bezug auf die voraussichtlich abnehmende Kundenzufriedenheit aufgrund falscher Lösungen sowie die steigenden Aufwände zur Nacharbeit zu sehen ist. Um jedoch im eigenen Unternehmenskontext optimale Resultate zu erzielen, ist es erforderlich, das Verhältnis zwischen angestrebter Automatisierungsrate und Genauigkeit der Klassifizierung unter individuellen Rahmenbedingungen und vorliegenden Daten zu optimieren.

4 Zusammenfassung und Ausblick

Maschinelles Lernen erfährt nach Jahrzehnten intensiver Forschung derzeit eine Renaissance. Dies liegt daran, dass in den letzten Jahren einige Barrieren für die Nutzung dieser Algorithmen weggefallen sind bzw. sich die Voraussetzungen für eine erfolgreiche Anwendung verbessert haben:

- Daten bzw. Big Data – etwa zum Training von Künstlichen Neuronalen Netzen – sind heute in einer nie gekannten Menge verfügbar und die Datenmenge steigt exponentiell.
- Rechenleistung und Speicherplatz sind so kostengünstig wie nie zuvor und können von Cloud-Anbietern, wie z.B. Amazon, Google oder Microsoft, kostenlos bzw. sehr preiswert genutzt werden.
- Die Performance von Algorithmen hat sich in den letzten Jahren verbessert.
- Es gibt viele kostenlos verfügbare Toolkits und Bibliotheken zur Entwicklung von KI-Anwendungen.

Um die Anwendungsmöglichkeiten und Potenziale im betriebswirtschaftlichen Bereich aufzuzeigen, wurde in diesem Artikel das Beispiel von Kundenbindungsprozessen vertieft. Grundsätzlich handelt es sich bei diesen Maschinellen Lernverfahren allerdings um eine „general purpose technology“ (Brynjolfsson und McAfee 2017); sie können für eine Vielzahl von Anwendungsbereichen eingesetzt werden.

Natürlich gibt es aber auch Einschränkungen bei der Nutzung Maschineller Lernverfahren. Insbesondere ist bei der Anwendung zu berücksichtigen, dass sie sich häufig wie eine „Black Box“ verhalten. Das bedeutet, dass die Algorithmen in vielen Fällen nicht preisgeben, warum eine bestimmte Entscheidung getroffen wurde. Prognostiziert ein Algorithmus beispielsweise, dass ein Kunde mit einer bestimmten Wahrscheinlichkeit nicht mehr loyal ist und kündigen wird, lassen sich die dahin-

tersteckenden Gründe nur schwer ermitteln. Damit ist es auch kaum möglich, allgemeingültige Handlungsempfehlungen für die Ausgestaltung bzw. Optimierung des Kundenmanagements abzuleiten. Vor diesem Hintergrund müssen Entscheidungsträger abwägen, unter welchen Bedingungen sie Maschinelle Lernverfahren in ihren Unternehmen für welche Problemstellungen einsetzen.

Zukünftig werden Verfahren des Maschinellen Lernens – trotz der fehlenden Erklärungskomponente – eine immer wichtigere Rolle für Wirtschaft und Gesellschaft spielen. In einer Studie untersucht die Stanford University (2017) die Auswirkungen künstlicher Intelligenz auf die menschliche Arbeit und das Leben. Zusammenfassend ist festzuhalten, dass aktuell gerade erst die metaphorische Spitze des Eisbergs sichtbar ist und weite Teile des Potenzials Maschinellen Lernens und künstlicher Intelligenz für Wirtschaft und Gesellschaft noch zu erschließen sind. Betrachtet man die Anbieterlandschaft so werden die Märkte für Künstliche Intelligenz und Maschinelles Lernen von US-amerikanischen und chinesischen Anbietern dominiert. Vor diesem Hintergrund ist es höchste Zeit, dass sich Entscheidungsträger aus Wirtschaft und Politik in Deutschland und Europa stärker mit diesen Algorithmen und ihren Auswirkungen auseinandersetzen, um den Anschluss bei diesen Zukunftstechnologien nicht zu verlieren.

Literatur

- Amazon Developer (2017) Alexa. <https://developer.amazon.com/public/solutions/alexa>. Zugegriffen: 29. Okt. 2017
- Apple (2017) Siri. <http://www.apple.com/ios/siri>. Zugegriffen: 29. Okt. 2017
- Batista G, Monard MC (2003) An analysis of four missing data treatment methods for supervised learning. *Appl Artif Intell* 17(5–6):519–533
- Bitkom (2017) Künstliche Intelligenz verstehen als Automation des Entscheidens. <https://www.bitkom.org/noindex/Publikationen/2017/Leitfaden/Bitkom-Leitfaden-KI-verstehen-als-Automation-des-Entscheidens-2-Mai-2017.pdf>. Zugegriffen: 17. Sept. 2017
- Breiman L (2001) Random forests. *Mach Learn* 45(1):5–32
- Bruhn M, Hadwich K (2012) Customer Experience – Eine Einführung in die theoretischen und praktischen Problemstellungen. In: Hadwich K (Hrsg) *Customer Experience*. Gabler, Wiesbaden, S 3–36
- Brynjolfsson E, McAfee A (2017) The business of artificial intelligence. *Harvard Business Review*. <https://hbr.org/cover-story/2017/07/the-business-of-artificial-intelligence>. Zugegriffen: 29. Sept. 2017
- Buckinx W, Van den Poel D (2005) Customer base analysis: partial defection of behaviourally loyal clients in a non-contractual FMCG retail setting. *Eur J Oper Res* 164(1):252–268
- Burez J, Van den Poel D (2007) CRM at a pay-TV company: using analytical models to reduce customer attrition by targeted marketing for subscription services. *Expert Syst Appl* 32(2):277–288
- Chesbrough H (2007) Business model innovation: it's not just about technology anymore. *Strategy Leadersh* 35(6):12–17
- Christensen C (1997) *The innovator's dilemma*. Harvard Business School Press, Cambridge
- Committee on Technology National Science and Technology Council (2016) Preparing for the future of artificial intelligence. Createspace independent publishing platform. https://obamawhitehouse.archives.gov/sites/default/files/whitehouse_files/microsites/ostp/NSTC/preparing_for_the_future_of_ai.pdf. Zugegriffen: 15. Okt. 2017
- Cortes C, Vapnik V (1995) Support-vector networks. *Mach Learn* 20(3):273–297
- Coussement K, Van den Poel D (2008) Churn prediction in subscription services: An application of support vector machines while comparing two parameter-selection techniques. *Expert Syst Appl* 34(1):313–327
- Coussement K, Van den Poel D (2009) Improving customer attrition prediction by integrating emotions from client/company interaction emails and evaluating multiple classifiers. *Expert Syst Appl* 36(3):6127–6134

- Dahlmeier D (2017) Machine learning: making customer service operations smarter and more strategic. <https://news.sap.com/machine-learning-smart-customer-service>. Zugegriffen: 6. Nov. 2017
- Damm W, Kalmar R (2017) Autonome Systeme. *Inform Spektrum* 40(5):400–408
- Davenport T, Kirby J (2016) Just how smart are smart machines? *MIT Sloan Manage Rev* 57(3):20–25
- Egle U, Keimer I, Hafner N (2014) KPIs zur Steuerung von Customer Contact Centern. In: Möller K, Schultze W (Hrsg) Produktivität von Dienstleistungen. Springer, Wiesbaden, S 505–543
- Erichsen J (2007) Benchmarking – von den Besten lernen. *Wiss Heute* 60(2):21–31
- Europäisches Parlament (2017) Bericht mit Empfehlungen an die Kommission zu zivilrechtlichen Regelungen im Bereich Robotik (2015/2103(INL)). <http://www.europarl.europa.eu/sides/getDoc.do?type=REPORT&reference=A8-2017-0005&language=DE>. Zugegriffen: 26. Okt. 2017
- Fachforum Autonome Systeme im Hightech-Forum (2017) Autonome Systeme – Chancen und Risiken für Wirtschaft, Wissenschaft und Gesellschaft. Kurzversion, Abschlussbericht. Fachforum Autonome Systeme im Hightech-Forum, Berlin
- Farquad MAH, Ravi V, Raju SB (2014) Churn prediction using comprehensible support vector machine: An analytical CRM application. *Appl Soft Comput* 19:31–40
- Google (2017) Google now. <https://www.google.com/landing/now>. Zugegriffen: 29. Okt. 2017
- Grace K, Salvatier J, Dafoe A, Zhang B, Evans O (2017) When will ai exceed human performance? Evidence from al experts. *arXiv:1705.08807*, S 1–21
- Guzella TS, Caminhas WM (2009) A review of machine learning approaches to Spam filtering. *Expert Syst Appl* 36(7):10206–10222
- Huber AS (2016) Das Digital Enterprise nimmt Gestalt an. In: Sendler U (Hrsg) Industrie 4.0 grenzenlos. Springer, Berlin Heidelberg, S 229–243
- Hung S, Yen DC, Wang H (2006) Applying data mining to telecom churn management. *Expert Syst Appl* 31(3):515–524
- Hurwitz J, Kaufman M, Bowles A (2015) Cognitive computing and big data analytics. Wiley, Hoboken
- IBM (2017) IBM Watson. <https://www.ibm.com/watson>. Zugegriffen: 28. Okt. 2017
- Jahromi AT, Stakhovych S, Ewing M (2014) Managing B2B customer churn, retention and profitability. *Ind Mark Manag* 43(7):1258–1268
- Kelly K (2014) The three breakthroughs that have finally unleashed ai on the world. <http://www.wired.com/2014/10/future-of-artificial-intelligence>. Zugegriffen: 14. Okt. 2017
- Kelly JE, Hamm S (2013) Smart machines—IBM's watson and the era of cognitive computing. Columbia University Press, New York
- Kirui C, Hong LL, Cheruiyot W, Kirui H (2013) Predicting customer churn in mobile telephony industry using probabilistic classifiers in data mining. *Int J Comput Sci Issues* 10(2):165–172
- Kohavi R (1995) A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th international joint conference of Artificial Intelligence*. Bd. 2, S 1137–1143
- Kruppa J, Schwarz A, Arminger G, Ziegler A (2013) Consumer credit risk: Individual probability estimates using machine learning. *Expert Syst Appl* 40(13):5125–5131
- Litjens G, Kooi T, Bejnordi EB, Setio AAA, Ciompi F, Ghafoorian M, van der Laak JAWM, van Ginneken B, Sánchez CI (2017) A survey on deep learning in medical image analysis. *Med Image Anal* 42:60–88
- Mainzer K (2016) Künstliche Intelligenz – Wann übernehmen die Maschinen? Springer, München
- Marsland S (2015) Machine learning: an algorithmic perspective. Taylor & Francis, Florida
- McCarthy J, Minsky ML, Rochester N, Shannon CE (1955) A proposal for the dartmouth summer research project on artificial intelligence. <http://jmc.stanford.edu/articles/dartmouth.html>. Zugegriffen: 30. Sept. 2017
- McKinsey (2017) A future that works: harnessing automation for a future that works. <https://www.mckinsey.com/~media/McKinsey/Global%20Themes/Digital%20Disruption/Harnessing%20automation%20for%20a%20future%20that%20works/MGI-A-future-that-works-Executive-summary.ashx>. Zugegriffen: 12. Okt. 2017
- Mitchell TM (1997) Machine learning. McGraw-Hill, New York
- Murphy KP (2012) Machine learning: a probabilistic perspective. MIT Press, Cambridge
- Murthy SK (1998) Automatic construction of decision trees from data: a multi-disciplinary survey. *Data Min Knowl Discov* 2(4):345–389
- Ngai EWT, Xiu L, Chau DCK (2009) Application of data mining techniques in customer relationship management: a literature review and classification. *Expert Syst Appl* 36(2):2592–2602
- Niefend F, Wiegand A (2010) Was sind Beschwerden? In: Ratajczak O (Hrsg) Erfolgreiches Beschwerde-management. Gabler, Wiesbaden, S 19–32
- Nilsson NJ (2014) Principles of artificial intelligence. Morgan Kaufmann, Burlington

- Osterwalder A, Pigneur Y (2010) Business model generation: a handbook for visionaries, game changers, and challengers. Wiley, Hoboken
- Patel J, Shah S, Thakkar P, Kotecha K (2015) Predicting stock and stock price index movement using trend deterministic data preparation and machine learning techniques. *Expert Syst Appl* 42(1):259–268
- Pennachin C, Goertzel B (2007) Artificial general intelligence. Springer, Berlin Heidelberg
- Quinlan JR (1986) Induction of decision trees. *Mach Learn* 1:81–106
- Reeves M, Ueda D (2016) Designing the machines that will design strategy. <https://hbr.org/2016/04/welcoming-the-chief-strategy-robot>. Zugegriffen: 30. Sept. 2017
- Reinartz W, Kumar V (2003) The impact of customer relationship characteristics on profitable lifetime duration. *J Mark* 67(1):77–99
- Reinartz W, Krafft M, Hoyer WD (2004) The customer relationship management process: its measurement and impact on performance. *J Mark Res* 41(3):293–305
- Russell SJ, Norvig P (2010) Artificial intelligence—a modern approach. Pearson, New Jersey
- SAE International (2016) SAE J3016: taxonomy and definitions for terms related to on-road motor vehicle automated driving systems
- Salesforce (2017) Salesforce einstein is artificial intelligence in business technology—salesforce EMEA. <https://www.salesforce.com/eu/products/einstein/overview>. Zugegriffen: 27. Okt. 2017
- SAP (2017a) Build your intelligent enterprise with machine learning, a case study with BASF. <http://events.sap.com/sapandasug/en/session/32268>. Zugegriffen: 30. Okt. 2017
- SAP (2017b) Machine learning applications and platform. <https://www.sap.com/products/leonardo/machine-learning.html>. Zugegriffen: 24. Okt. 2017
- SAP (2017c) SAP API business hub: SAP Leonardo machine learning—business services. <https://api.sap.com/shell/discover/contentpackage/SAPLeonardoMLBusinessServices>. Zugegriffen: 10. Nov. 2017
- SAP (2017d) SAP service ticket intelligence. <https://help.sap.com/viewer/934ccff77ddb4fa2bf268a0085984db0/1708/en-US>. Zugegriffen: 6. Nov. 2017
- Schapire RE, Freund Y (2012) Boosting: foundations and algorithms. MIT Press, Cambridge
- Schroeck M, Shockley R, Smart J, Romero-Morales D, Tufano P (2012) Analytics: the real-world use of big data. IBM Global Business Services, S 1–20
- Silver D, Huang A, Maddison CJ, Guez A, Sifre L, van den Driessche G, Schrittwieser J, Antonoglou I, Panneershelvam V, Lanctot M, Dieleman S, Grewe D, Nham J, Kalchbrenner N, Sutskever I, Lillicrap T, Leach M, Kavukcuoglu K, Graepel T, Demis Hassabis D (2016) Mastering the game of Go with deep neural networks and tree search. *Nature* 529:484–489
- Silver D, Schrittwieser J, Simonyan K, Antonoglou I, Huang A, Guez A, Hubert T, Baker L, Lai M, Bolton A, Chen Y, Lillicrap T, Hui F, Sifre L, van den Driessche G, Graepel T, Hassabis D (2017) Mastering the game of Go without human knowledge. *Nature* 550:354–359
- Stanford University (2017) One Hundred Year Study on Artificial Intelligence (AI100). <https://ai100.stanford.edu>. Zugegriffen: 17. Nov. 2017
- Susto GA, Schirru A, Pampuri S, McLoone S, Beghi A (2015) Machine learning for predictive maintenance: a multiple classifier approach. *IEEE Trans Ind Inform* 11(3):812–819
- Tamaddon A, Stakhovych S, Ewing M (2016) Comparing churn prediction techniques and assessing their performance a contingent perspective. *J Serv Res* 19(2):123–141
- Vafeiadis T, Diamantaras KI, Sarigiannidis G, Chatzisavvas KC (2015) A comparison of machine learning techniques for customer churn prediction. *Simul Model Pract Theory* 55:1–9
- Vallis H (2017) The art and science of reducing involuntary subscriber churn. Forrester consulting thought leadership paper [1–13MQMED], S 1–11
- Verbeke W, Martens D, Baesens B (2014) Social network analysis for customer churn prediction. *Appl Soft Comput* 14:431–446
- Wahlster W (2017) Künstliche Intelligenz als Grundlage autonomer Systeme. *Inform Spektrum* 40(5): 409–418
- Wang YF, Chiang DA, Hsu MH, Lin CJ, Lin IL (2009) A recommender system to avoid customer churn: a case study. *Expert Syst Appl* 36(4):8071–8075
- Watson HJ (2017) Preparing for the cognitive generation of decision support. *MIS Q Exec* 16(13):153–169
- Witten IH, Frank E, Hall MA, Pal CJ (2017) Data mining: practical machine learning tools and techniques. Elsevier, Cambridge
- World Economic Forum (2016) Digital transformation of industries: digital enterprise. <http://reports.weforum.org/digital-transformation/wp-content/blogs.dir/94/mp/files/pages/files/digital-enterprise-narrative-final-january-2016.pdf>. Zugegriffen: 11. Okt. 2017

- Yin S, Zhu X, Jing C (2014) Fault detection based on a robust one class support vector machine. *Neuro-computing* 145:263–268
- Yu L, Liu H (2004) Efficient feature selection via analysis of relevance and redundancy. *J Mach Learn Res* 5:1205–1224
- Zorn S, Jarvis W, Bellman S (2010) Attitudinal perspectives for predicting churn. *J Res Interact Mark* 4(2):157–169